Metode predictive de Data Mining

-Predicția accidentului vascular cerebral-

Chiorean Cristina-Ioana

Dragotă Melisa

1.Introducere

Descrierea problemei și a obiectivelor. De ce sunteți interesați de problema respectivă? Ce așteptări aveți de la analiza realizată?

Accidentele vasculare cerebrale (AVC) reprezintă o amenințare majoră pentru sănătatea și bunăstarea noastră. Ele pot provoca leziuni cerebrale grave, dizabilități și chiar deces. În acest context, importanța prevenirii AVC-urilor nu poate fi subestimată. Prin adoptarea unor măsuri preventive adecvate, putem reduce semnificativ riscul de a dezvolta această afecțiune debilitantă. În acest sens, am încercat să creăm cu ajutorul predicțiilor un punct de referință în ceea ce privește factorii de risc ai acestei boli, pentru a ajuta la prevenirea acesteia.

Prevenirea AVC-urilor începe cu conștientizarea și gestionarea factorilor de risc cheie. Controlul tensiunii arteriale este esențial, deoarece hipertensiunea arterială este unul dintre cei mai importanți factori de risc pentru AVC. Monitorizarea regulată a tensiunii arteriale și adoptarea unui stil de viață sănătos, care include o alimentație echilibrată și exerciții fizice regulate, pot ajuta la menținerea unor niveluri optime ale tensiunii arteriale.

Renunțarea la fumat este, de asemenea, o măsură vitală în prevenirea AVC-urilor. Fumatul crește riscul de formare a cheagurilor de sânge și de deteriorare a arterelor, contribuind astfel la apariția AVC-urilor. Prin abandonarea fumatului, reducem semnificativ riscul de a suferi un AVC și avem un impact pozitiv asupra sănătății noastre generale.

Controlul nivelului de colesterol este, de asemenea, crucial în prevenirea AVC-urilor. Nivelurile ridicate de colesterol pot duce la acumularea de depozite de grăsime în artere, ceea ce crește riscul de blocare a acestora și de formare a cheagurilor de sânge. Prin adoptarea unei alimentații sănătoase, bogate în fructe, legume și grăsimi sănătoase, precum și prin evitarea alimentelor procesate și a grăsimilor saturate, putem menține nivelurile de colesterol sub control.

Activitatea fizică regulată și exercițiile cardiovasculare ne ajută să menținem arterele sănătoase și flexibile, reducând riscul de AVC. Prin creșterea fluxului sanguin și întărirea sistemului cardiovascular, exercițiile fizice ne oferă o protecție suplimentară împotriva apariției AVC-urilor.

Gestionarea stresului și adoptarea unor tehnici de relaxare, cum ar fi meditația, yoga sau respirația profundă, sunt aspecte importante în prevenirea AVC-urilor. Stresul cronic poate afecta negativ sistemul cardiovascular și poate crește riscul de afecțiuni vasculare.

Mai mult, menținerea unei greutăți sănătoase și controlul diabetului zaharat sunt alte aspecte esențiale în prevenirea AVC-urilor. Excesul de greutate și diabetul pot contribui la apariția hipertensiunii arteriale și a nivelurilor ridicate de colesterol, crescând astfel riscul de AVC.

Educația și conștientizarea cu privire la semnele și simptomele AVC-urilor sunt, de asemenea, cruciale. Cunoașterea rapidă a semnelor unui AVC și căutarea imediată a asistenței medicale pot face diferența între viață și moarte, precum și între recuperare și dizabilitate permanentă.

În predicția noastră am încercat să surprindem cât mai bine factorii enumerați mai sus, împreună cu alte variabile importante pentru crearea acesteia. Cu ajutorul acestei analize, dorim să facem cunoscute cauzele relevante ale acestei boli pentru a ajuta la prevenția sa.

Prevenirea AVC-urilor este un efort colectiv, în care fiecare individ are un rol important de jucat. Prin adoptarea unui stil de viață sănătos, prin monitorizarea factorilor de risc și prin căutarea asistenței medicale adecvate, putem proteja sănătatea noastră și putem reduce în mod semnificativ incidența și impactul acestor afecțiuni devastatoare. Nu subestimați importanța prevenirii AVC-urilor și acționați acum pentru a vă proteja creierul și viața.

2.Studiu bibliografic

Prezentați câteva referințe bibliografice referitoare la problema propusă și abordările avute de autorii lucrărilor științifice.

Classification of Ischemic Stroke using Machine Learning Algorithms (https://www.researchgate.net/profile/Adil-Yousif-6/publication/308180906_Classification_of_Ischemic_Stroke_using_Machine_Learning_Algorithms/links/6260887c8e6d637bd1f0d977/Classification-of-Ischemic-Stroke-using-Machine-Learning-Algorithms.pdf)

Machine Learning for Brain Stroke: A Review (https://www.sciencedirect.com/science/article/abs/pii/S1052305720305802)

3. Descrierea datelor/preprocesare

Ce fel de date au fost colectate? Descrierea atributelor, Ce probleme de structura a setului de date ar putea afecta cercetarea? (ex. multe date lipsă) Se vor face referire la metodele utilizate in SAS Enterprise Miner.

În cadrul proiectului nostru, ne-am dorit să realizăm o predicție pentru nivelul de risc al unor indivizi, unde am ales un set de date numit “Risk Prediction” ce reprezintă o colecție de date care explorează factorii de risc și predictori asociați accidentelor vasculare cerebrale (AVC). Setul de date conține informații pe baza parametrilor de intrare precum sexul, vârsta, diferite boli și stilul de viață al fiecărui pacient, utilizate pentru a identifica potențiali factori de risc pentru AVC. Acest set de date este provenit din cadrul datelor oferite de organizația mondiala a sănătății (OMS). Pentru acest proiect, a fost utilizat un set de date în format csv disponibil pe Kaggle pentru anul 2015. Datele proiectului au fost colectate folosind un set de date în format xls pe Kaggle. Setul de date original a avut răspunsuri de la peste 700.000 de persoane. Nu am putut găsi anul în care a fost realizat acest set de date.

În urma analizei noastre am observat că setul nostru format din 12 variabile de date nu este atât de balansat, ceea ce ne-a complicat puțin modul de realizare a predicției. Pentru ca realizarea acestui set de date să fie cât mai precis posibil, am ales ca și variabilă țintă Stroke ce este formată din variabile binare, mai extact 0, care reprezintă absența riscului de atac cerebral, sau 1, care indică indivizi care prezintă risc de atac cerebral. În partea de jos vom prezenta variabilele prezente în acest set de date:

- id: identificator unic
- gender: "Bărbat", "Femeie" sau "Alt gen"
- age: vârsta pacientului
- hypertension: 0 dacă pacientul nu are hipertensiune, 1 dacă pacientul are hipertensiune

- heart_disease: 0 dacă pacientul nu are afecțiuni cardiace, 1 dacă pacientul are o afecțiune cardiacă
- ever_married: "Nu" sau "Da"
- work_type: "Copii", "Angajat de stat", "Nu a fost angajat niciodată", "Angajat în sectorul privat" sau "Autonom"
- Residence_type: "Rural" sau "Urban"
- avg_glucose_level: nivelul mediu de glucoză din sânge
- bmi: indicele de masă corporală
- smoking_status: "fumat în trecut", "nu a fumat niciodată", "fumează" sau "Necunoscut"*
- stroke: 1 dacă pacientul a suferit un accident vascular cerebral sau 0 în caz contrar

4. Metode de data mining utilizate

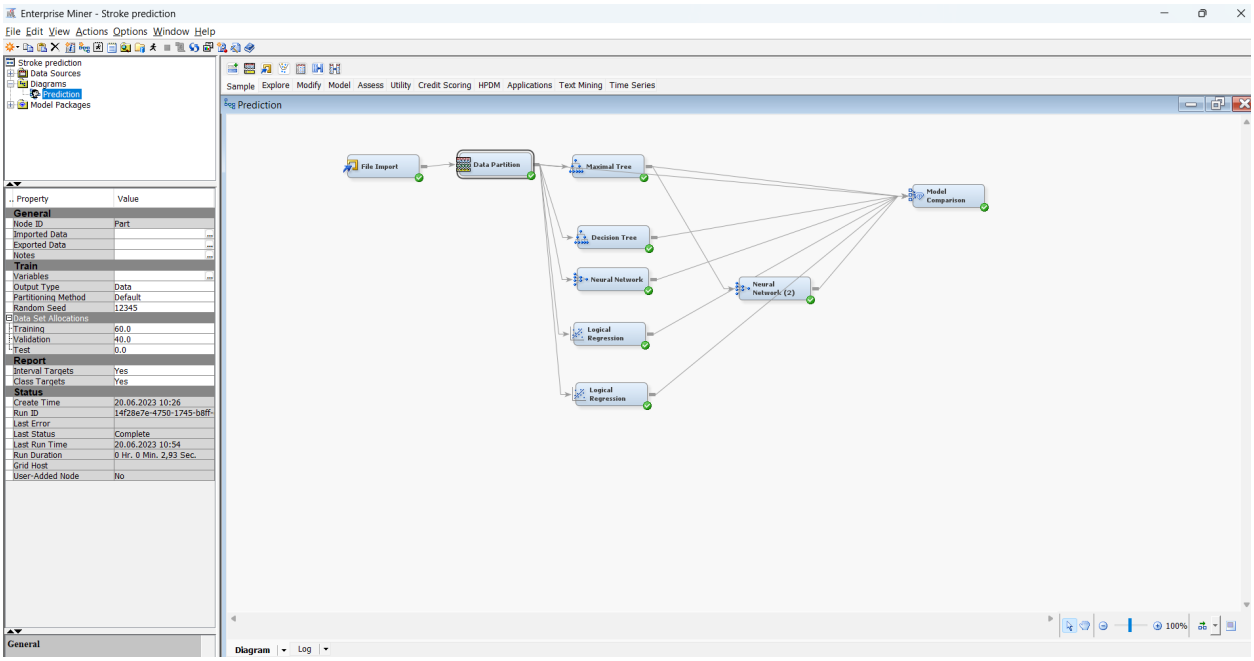
Descrieți metodele de data mining folosite pentru a modela datele, parametrii folosiți și motivele pentru care au fost alese. Dificultăți în utilizare.

În cadrul clasificării noastre am ales să folosim metode precum: importarea unui set de date, utilizarea unui data partition, adăugarea a doi arbori de decizie, unul maximal și altul inițial, două regresii, una în forward și una in backward și două rețele neuronale, la final utilizând un model comparison. Pentru a ajusta setul de date pentru a obține data valide am împărțit setul de date în format de 60% pentru antrenare și 40% pentru validare, iar pentru test 0%.

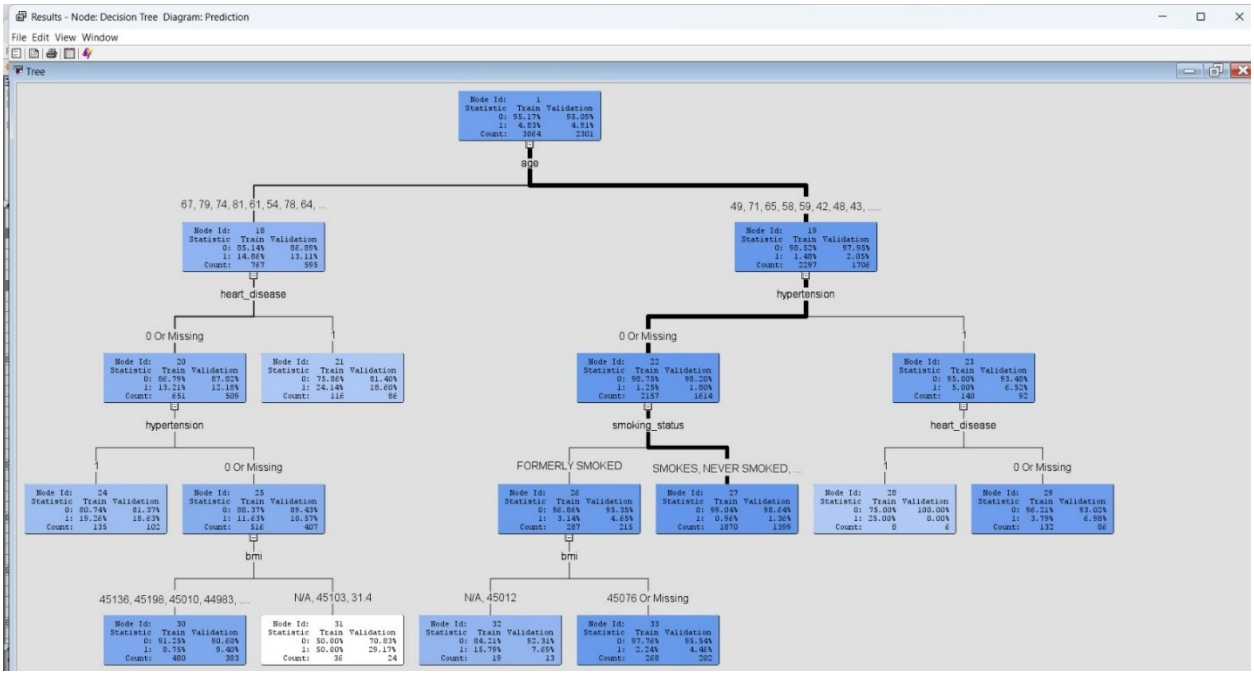
Prezentarea variabilelor:

age	Input	Nominal	No		No	.	.
avg_glucose_le	Input	Binary	No		No	.	.
bmi	Input	Binary	No		No	.	.
ever_married	Rejected	Nominal	No		No	.	.
gender	Input	Nominal	No		No	.	.
heart_disease	Input	Binary	No		No	.	.
hypertension	Input	Binary	No		No	.	.
id	ID	Nominal	No		No	.	.
Residence_typ	Rejected	Nominal	No		No	.	.
smoking_statu	Input	Nominal	No		No	.	.
stroke	Target	Binary	No		No	.	.
work_type	Rejected	Nominal	No		No	.	.

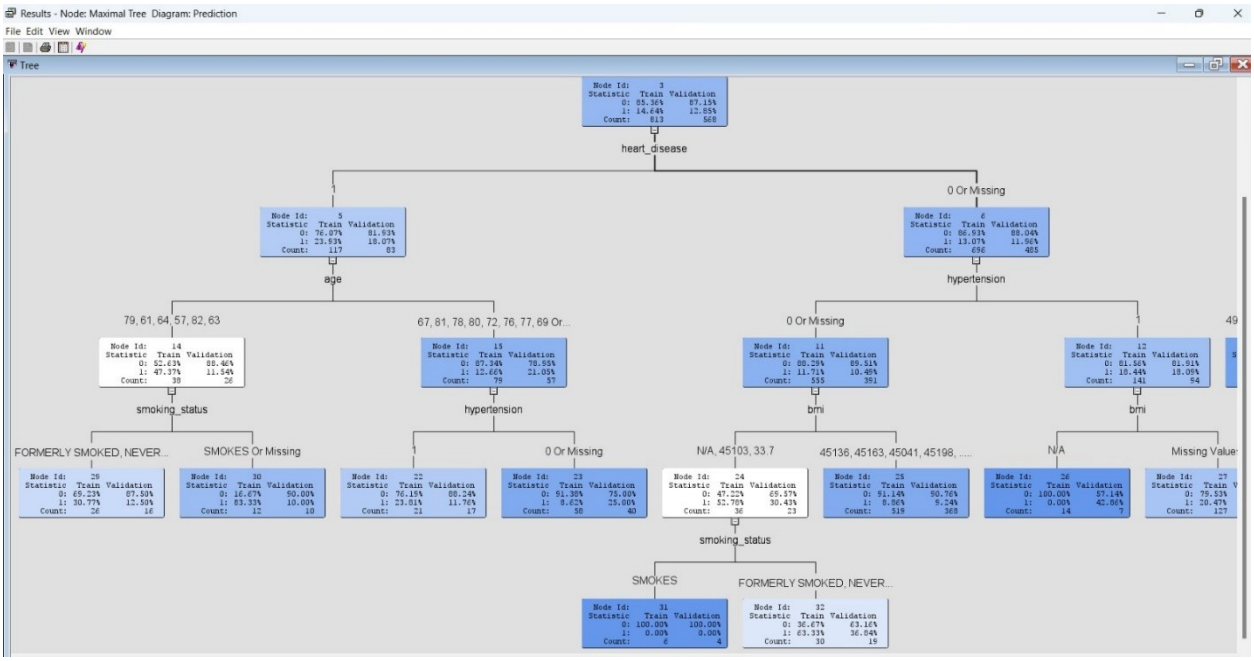
Diagrama SAS Enterprise Miner:

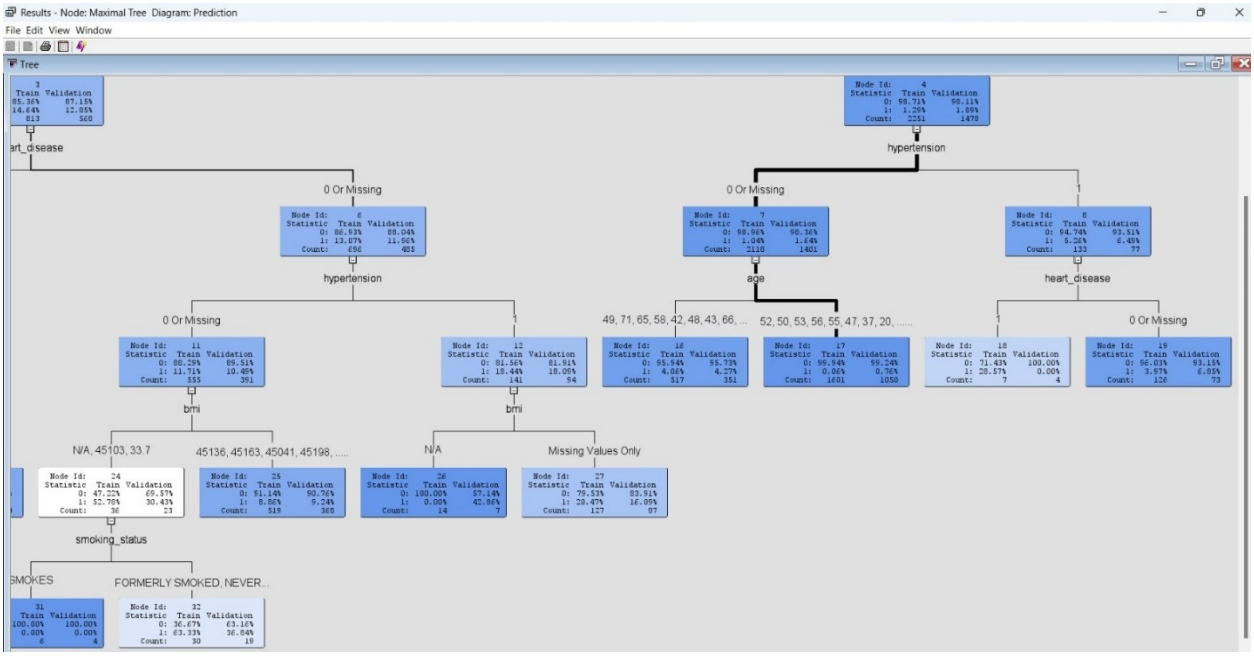


Grafic arbore inițial:

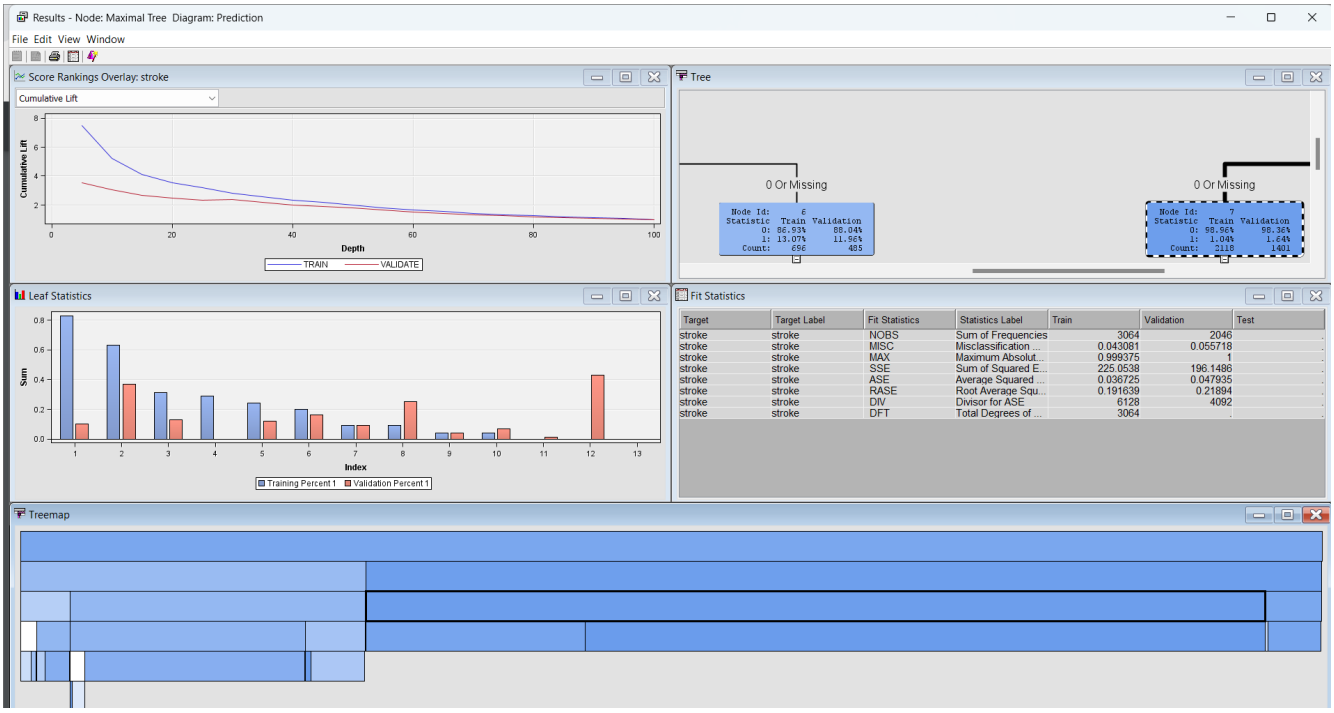


Grafic arbore maximal:

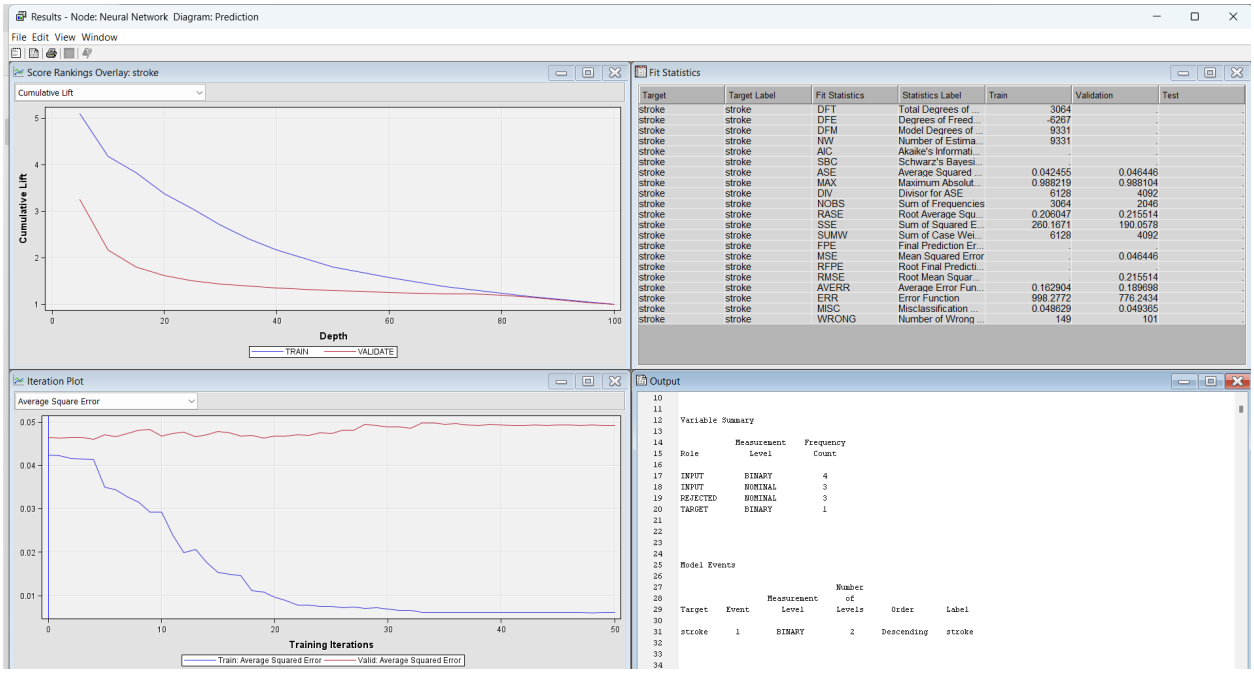




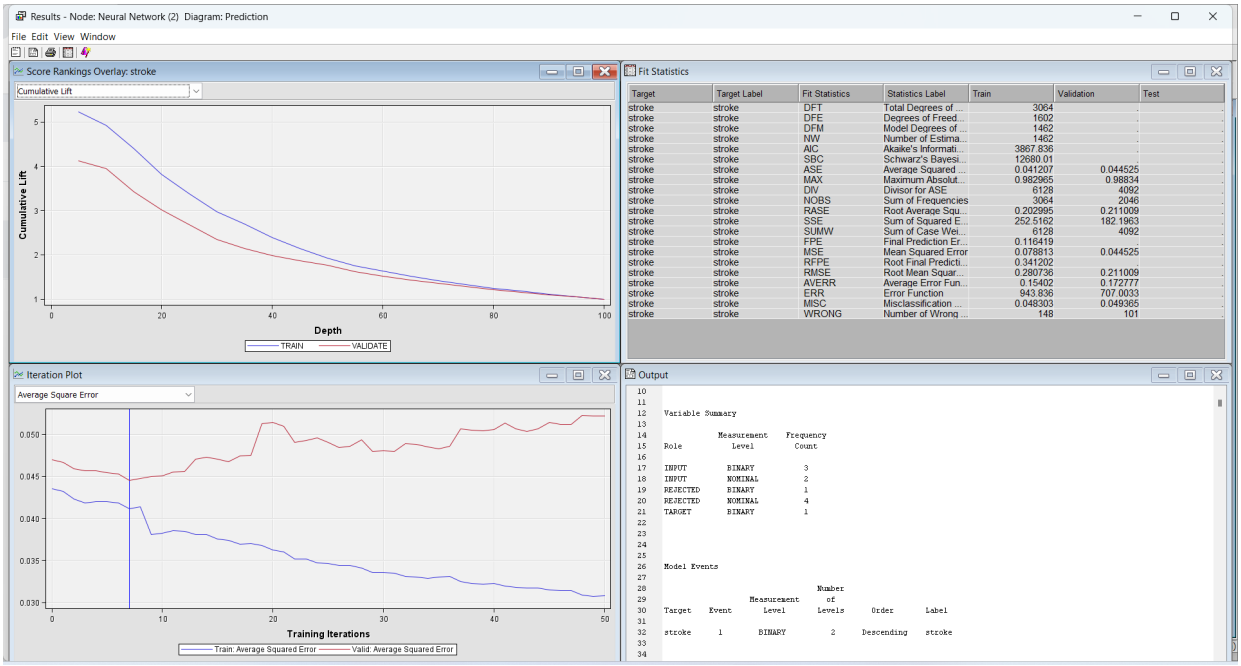
Rezultate arbore maximal:



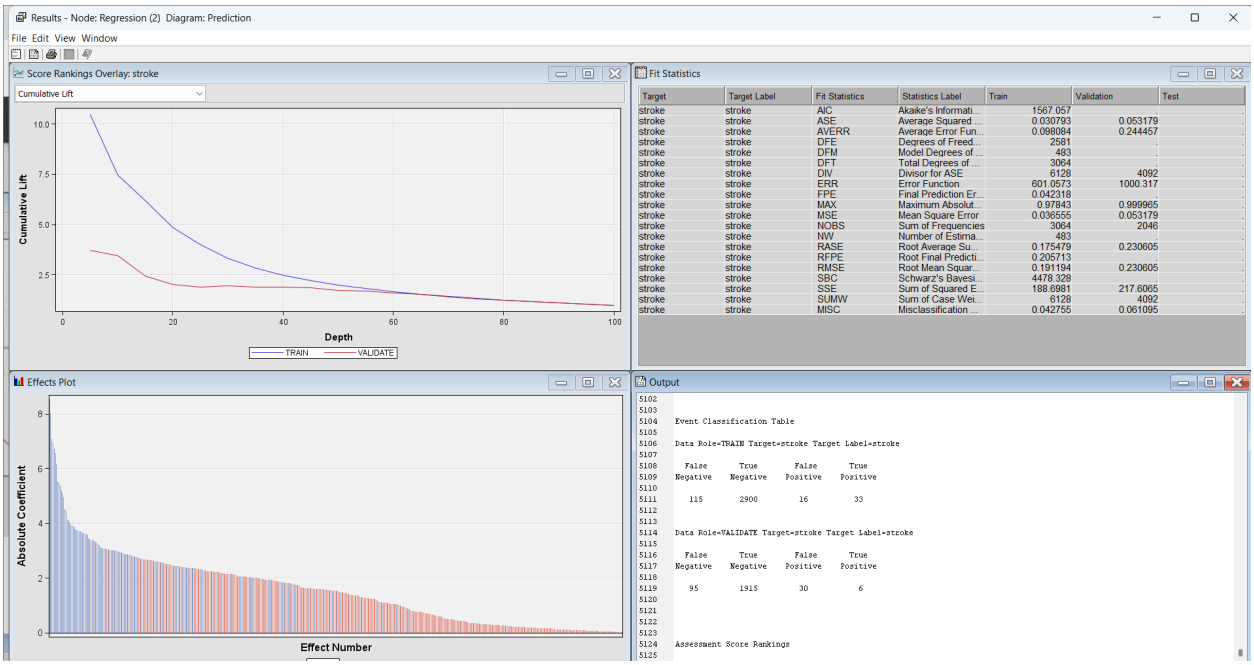
Neural Network pe Data Partition:



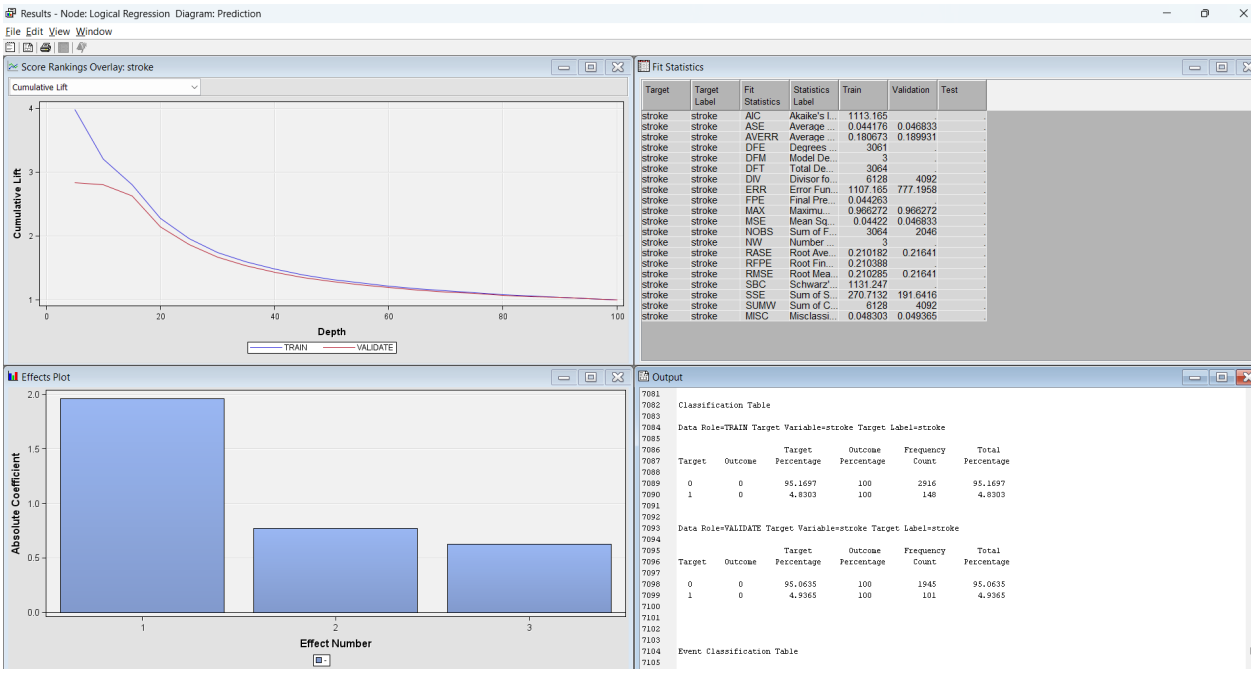
Neuronal Network pentru arborele maximal:



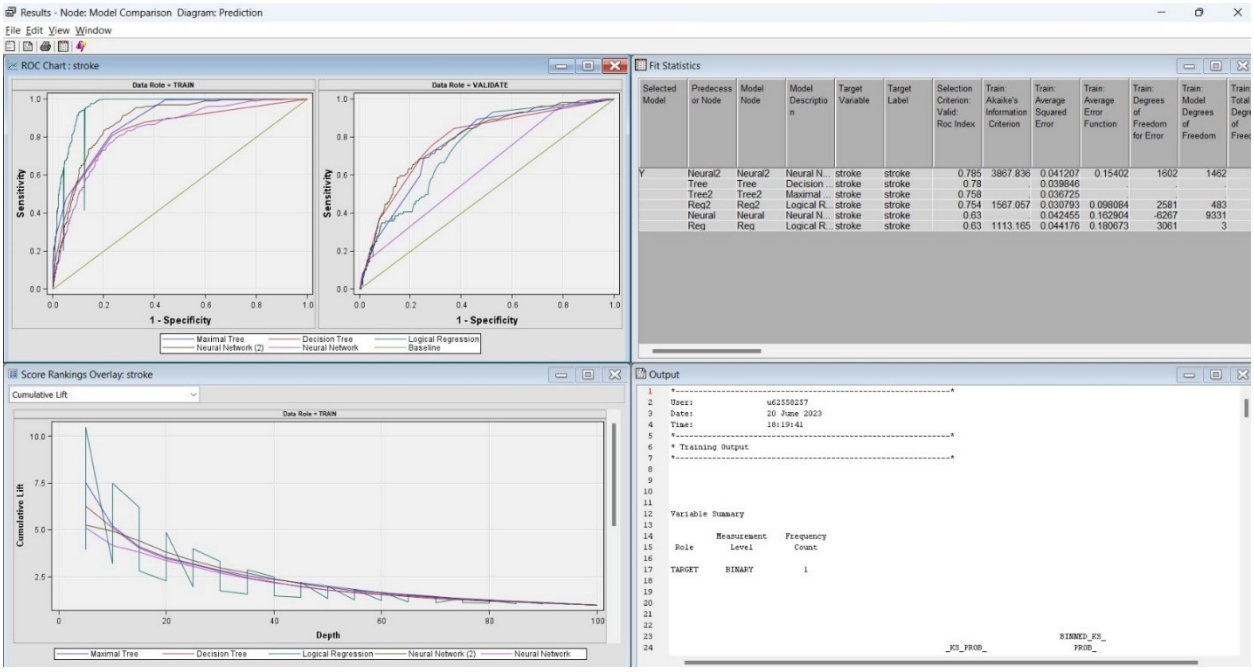
Regresia logistică model forward:



Regresia logistică model backward:



Compararea modelelor



B. Interpretarea rezultatelor obținute în contextul problemei formulate

În urma analizei noastre vom lua în considerare rezultatele obținute în cadrul criteriilor selecționate Root Average Squared Error și Misclassification Rate .

- **Arbore Maximal**

Putem extrage că RASE este de 19,1639% și MR este de 43,081%. În cadrul arborelui maximal am folosit metoda de training cu opțiunea de use frozen tree pentru a folosi varianta setată în cadrul interactive tree. Variabilele folosite în cadrul acestei metode sunt: age, heart_disease, hypertension, smoking_status și bmi. Având în vedere datele obținute am observat că persoanele care sunt fumătoare și totodată au o vârstă mai înaintată au un risc mai mare de a face accident vascular cerebral.

- **Arbore inițial**

Pentru a performa setul de date am folosit în cadrul assessment measure metoda Decision. Din cele 12 variabile folosite în cadrul predicției noastre, se poate observa faptul că cele mai importante variabile sunt age, bmi, heart_disease, hypertension, smoking_status. Procentajele în cadrul acestui arbore fiind următoarele: RASE 19,9615% și MR 48,303%. Cu ratele mici de eroare, putem identifica cu ușurință legătura dintre datele inițiale și variabila țintă, având astfel valori apropiate față de valoarea de validation.

Variable Importance

Variable Name	Label	Number of Splitting Rules	Importance	Validation Importance	Ratio of Validation to Training Importance
age	age	1	1.0000	1.0000	1.0000
bmi	bmi	2	0.7648	0.0000	0.0000
heart_disease	heart_disease	2	0.3836	0.1754	0.4572
hypertension	hypertension	2	0.2801	0.3726	1.3302
smoking_status	smoking_status	1	0.1068	0.1930	1.8066

- **Neural Network pe Data Partition:**
  Optimizarea nu s-a încheiat și aveam nevoie de mai multe iterații, ceea ce a făcut imposibil de efectuat raportul de în care se exprimau validările pozitive și negative și procentajele lor.

- **Neuronal Network pentru arborele maximal:**
  Situații:
  1. S-a așteptat negativ și s-a obținut pozitiv(Fals Negativ): 95,0635%
  2. S-a așteptat pozitiv și s-a obținut negativ (Fals Pozitiv): 4,9365%

- **Regresia logică model forward:**
  Situații:
  1. S-a așteptat negativ și s-a obținut negativ (Negativ): 93,5973%
  2. S-a așteptat pozitiv și s-a obținut negativ (Fals Pozitiv): 4,6432%
  3. S-a așteptat negativ și s-a obținut pozitiv (Fals Negativ): 1,4663%
  4. S-a așteptat pozitiv și s-a obținut pozitiv (Pozitiv): 0,2933%

- **Regresia logică model backward:**
  Situații:

1. S-a așteptat negativ și s-a obținut pozitiv(Fals Negativ):95,0635 %
2. S-a așteptat pozitiv și s-a obținut negativ (Fals Pozitiv): 4,9365%

• Compararea modelelor

Cel mai performant model este Neural Network pentru arborele maximal realizat pe datele inițiale cu RASE de 20,2995% și MR de 4,8303%. Cel mai slab performant model este Regresia logistică model forward cu RASE de 21,0182% și MR de 4,8303%. Putem astfel să observăm faptul că avem valoare identică la cele două modele la indicele de MR, diferența între performanța acestora fiind determinată de valorea RASE. Cu toate acestea, prima predicție are RASE mai mică decât cea de-a doua predicție, ceea ce indică o performanță relativ mai bună a modelului în ceea ce privește acuratețea predicțiilor.

6. Bibliografie- Resursele bibliografice utilizate

https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset